

المشروع الفصلي

دراسة النشاط البشري (النشاط الرياضي)

Study of human activity (sports activity)

اشراف الدكتورة :

ماجدة البكور

إعداد الطالب :

عبدالكريم سمرة

2026/2025

شهادة مشرف :

الاسم :

التاريخ :

التوقيع :

المخلص :

تُعد دراسة النشاط البشري، وبشكل خاص النشاط الرياضي، من المجالات البحثية المهمة التي تجمع بين العلوم الصحية والتقنية وعلوم البيانات، لما لها من دور أساسي في فهم سلوك الإنسان الحركي وتحليل أدائه البدني. يهدف هذا النوع من الدراسات إلى تحليل الحركات الجسدية التي يقوم بها الإنسان أثناء ممارسة الأنشطة الرياضية المختلفة، مثل المشي، الجري، القفز، وتمارين اللياقة البدنية، من أجل تحسين الأداء الرياضي، تقليل مخاطر الإصابات، وتعزيز الصحة العامة.

تعتمد دراسة النشاط الرياضي على جمع البيانات الحركية باستخدام تقنيات حديثة مثل المستشعرات القابلة للارتداء، ووحدات قياس القصور الذاتي، والهواتف الذكية، التي تتيح تسجيل معلومات دقيقة عن التسارع، السرعة، الاتجاه، ومعدل الحركة. بعد جمع البيانات، يتم معالجتها وتحليلها باستخدام خوارزميات متقدمة وتقنيات التعلم الآلي لاستخلاص الأنماط الحركية المميزة لكل نشاط رياضي، مما يسمح بالتمييز بين الأنشطة المختلفة بدقة عالية.

تساهم نتائج هذه الدراسات في عدة مجالات، من أبرزها تطوير البرامج التدريبية المخصصة للرياضيين، تحسين كفاءة التمارين الرياضية، ومراقبة التقدم البدني بشكل موضوعي. كما تُستخدم في المجال الطبي لإعادة التأهيل الحركي، حيث تساعد في متابعة حالة المرضى وتقييم تطورهم الحركي بعد الإصابات أو العمليات الجراحية. إضافة إلى ذلك، تلعب دوراً مهماً في أنظمة المراقبة الصحية الذكية التي تهدف إلى تشجيع نمط حياة نشط وتقليل الخمول البدني.

إن دراسة النشاط الرياضي تمثل حلقة وصل بين الإنسان والتكنولوجيا، وتساهم في بناء أنظمة ذكية قادرة على فهم الحركة البشرية والتفاعل معها. ومن خلال التطور المستمر في تقنيات الاستشعار والتحليل، أصبح من الممكن الوصول إلى نتائج أكثر دقة وموثوقية، مما يجعل هذا المجال من الركائز الأساسية في تطوير التطبيقات الصحية والرياضية الحديثة، وداعماً رئيسياً للأبحاث المستقبلية في مجال النشاط البشري.

Abstract:

The study of human activity, particularly sports activity, is an important research area that combines health sciences, technology, and data science, due to its fundamental role in understanding human motor behavior and analyzing physical performance. This type of study aims to analyze the physical movements performed by humans during various sports activities, such as walking, running, jumping, and fitness exercises, in order to improve athletic performance, reduce the risk of injuries, and promote overall health.

The study of sports activity relies on collecting motion data using modern technologies such as wearable sensors, inertial measurement units, and smartphones, which allow for the recording of accurate information about acceleration, velocity, direction, and movement rate. After data collection, the data is processed and analyzed using advanced algorithms and machine learning techniques to extract the distinctive movement patterns of each sports activity, allowing for accurate differentiation between different activities.

The results of these studies contribute to several fields, most notably the development of customized training programs for athletes, improving the efficiency of exercise, and objectively monitoring physical progress. They are also used in the medical field for motor rehabilitation, helping to monitor patients' conditions and assess their motor development after injuries or surgeries. In addition, they play an important role in smart health monitoring systems that aim to encourage an active lifestyle and reduce physical inactivity.

The study of sports activity represents a link between humans and technology, and contributes to building intelligent systems capable of understanding and interacting with human movement. Through continuous advancements in sensing and analysis technologies, it has become possible to obtain more accurate and reliable results, making this field a fundamental pillar in the development of modern health and sports applications, and a major support for future research in the field of human activity.

فهرس المحتويات

الملخص.....(3)

الفهرس (5)

فهرس جداول (7)

فهرس اشكال (8)

جدول المصطلحات (9)

الفصل الأول:

1.1 المقدمة (12)

2.1 منهجية المشروع (13)

1.2.1 مشكلة المشروع (15)

2.2.1 اهداف المشروع (16)

3.2.1 الدراسات المرجعية (18)

الفصل الثاني:

- 2.1 مقدمة.....(22)
- 2.2 شرح التمارين الرياضية المستخدمة في المشروع.....(23)
- 3.2 الذكاء الصناعي وتطبيقاته في المجال الرياضي.....(28)
- 4.2 الشبكات العصبونية المستخدمة في المشروع.....(30)
- 5.2 تقييم أداء النماذج.....(31)

الفصل الثالث:

- 1.3 شرح البيانات.....(36)
- 2.3 منهجية البيانات.....(39)
- 4.3 تصميم النموذج وبناءه (Model Design and Architecture).....(40)
- 5.3 مرحلة تدريب النموذج (Model Training).....(41)
- 6.3 مرحلة الاختبار والتقييم (Testing and Evaluation).....(42)
- 7.3 الخلاصة.....(51)
- المراجع.....(52)

فهرس الجداول :

1- جدول المصطلحات 8

2- جدول مقارنة الدراسات السابقة 17

فهرس الاشكال :

- شكل (3.5.1) توزيع البيانات حسب نوع التمرين الرياضي 43
- شكل (3.5.2) توزيع التسلسلات الزمنية (Sequences) لكل تمرين رياضي 44
- شكل (3.5.3) مخطط تقسيم البيانات إلى مجموعة التدريب ومجموعة التحقق 45
- شكل (3.5.4) مقارنة دقة التدريب ودقة التحقق عبر مراحل التدريب 46
- شكل (3.5.5) مقارنة خسارة التدريب وخسارة التحقق عبر مراحل التدريب 47
- شكل (3.5.6) مصفوفة الالتباس لنتائج تصنيف التمارين الرياضية 48

جدول المصطلحات :

الاسم بالعربي	الاسم بالإنكليزي	الشرح
الذكاء الاصطناعي	Artificial Intelligence	فرع من علوم الحاسوب يهدف إلى تصميم أنظمة قادرة على محاكاة الذكاء البشري مثل التعلّم والاستنتاج واتخاذ القرار.
التعلّم الآلي	Machine Learning	أحد فروع الذكاء الاصطناعي يعتمد على خوارزميات تتعلّم الأنماط من البيانات دون برمجة صريحة.
التعلّم العميق	Deep Learning	فرع من التعلّم الآلي يعتمد على الشبكات العصبية العميقة لاستخلاص تمثيلات معقدة من البيانات.
رؤية الحاسوب	Computer Vision	مجال يهتم بتمكين الحاسوب من فهم وتحليل الصور ومقاطع الفيديو الرقمية.
تقدير وضعية الجسم	Human Pose Estimation	تقنية تهدف إلى تحديد مواقع مفاصل جسم الإنسان في الصور أو الفيديو باستخدام نماذج تعلم عميق.
MediaPipe	MediaPipe	إطار عمل مفتوح المصدر من Google يُستخدم لاستخراج وتتبع نقاط الجسم في الزمن الحقيقي.
نقطة مرجعية	Landmark	نقطة تمثل أحد مفاصل الجسم مثل الكتف أو الركبة أو المرفق.
الإحداثيات	Coordinates	قيم رقمية تعبّر عن موقع النقطة في الصورة باستخدام المحورين x و y.
الخصائص	Features	قيم رقمية مستخرجة من البيانات تُستخدم كمدخلات لتدريب النموذج.
زوايا المفاصل	Joint Angles	الزوايا الناتجة عن ثلاث نقاط تمثل مفصلاً معيناً وتعبّر عن حركة العضو.
المسافات المعيارية	Normalized Distances	مسافات بين نقاط الجسم بعد تطبيعها بالنسبة لمسافة مرجعية لتقليل تأثير اختلاف أحجام الأجسام.
التطبيع	Normalization	عملية تهدف إلى توحيد نطاق القيم العددية للخصائص لتحسين أداء النموذج.
التسلسل الزمني	Temporal Sequence	مجموعة متتابعة من الإطارات تمثل حركة الجسم عبر الزمن.
طول التسلسل	Sequence Length	عدد الإطارات المستخدمة لتمثيل الحركة، وقد تم تحديده في المشروع بـ 30 إطاراً.

الشبكات العصبية المتكررة	Recurrent Neural Networks	نوع من الشبكات العصبية مصمم لمعالجة البيانات المتسلسلة مثل السلاسل الزمنية.
BiLSTM	Bidirectional Long Short-Term Memory	شبكة عصبية متكررة ثنائية الاتجاه قادرة على تعلم الأنماط الزمنية من الماضي والمستقبل معاً.
التدريب	Training	مرحلة تعلم النموذج من بيانات التدريب بهدف تقليل الخطأ.
التحقق	Validation	مرحلة تقييم أداء النموذج أثناء التدريب باستخدام بيانات لم تُستخدم في التعلم.
الاختبار	Testing	مرحلة تقييم النموذج النهائي باستخدام بيانات جديدة لم يسبق له رؤيتها.
مصفوفة الالتباس	Confusion Matrix	أداة إحصائية تُستخدم لتحليل أداء نموذج التصنيف.
الدقة	Accuracy	نسبة التنبؤات الصحيحة إلى إجمالي عدد التنبؤات.
الاسترجاع	Recall	قدرة النموذج على اكتشاف العينات الصحيحة لكل فئة.
الدقة الإيجابية	Precision	نسبة التنبؤات الصحيحة من بين جميع التنبؤات الإيجابية.
درجة F1	F1-Score	مقياس يوازن بين الدقة والاسترجاع لتقييم أداء النموذج.
ترميز التصنيفات	Label Encoding	تحويل التصنيفات النصية إلى قيم رقمية ليتمكن النموذج من معالجتها.
فك ترميز التصنيفات	Label Decoding	تحويل القيم الرقمية الناتجة عن النموذج إلى أسماء التمارين الأصلية.

1- الفصل الاول :

مقدمة عن المشروع

1.1 مقدمة:

يشهد العالم في الوقت الحاضر تطورًا متسارعًا في مجالات التكنولوجيا الرقمية والذكاء الاصطناعي، مما ساهم في توظيف هذه التقنيات في دراسة وتحليل السلوك البشري بمختلف أشكاله، ويُعد النشاط الرياضي أحد أبرز مظاهر هذا السلوك. يركز هذا المشروع على دراسة النشاط البشري المرتبط بالحركة البدنية والأنشطة الرياضية، من خلال تحليل البيانات الحركية بهدف فهم أنماط الحركة، تقييم الأداء البدني، وتحسين جودة الحياة والصحة العامة.

تتبع أهمية هذا المشروع من الحاجة المتزايدة إلى أنظمة ذكية قادرة على مراقبة وتحليل النشاط الرياضي بدقة وموضوعية، سواء للأفراد العاديين أو الرياضيين المحترفين. إذ تتيح دراسة النشاط الرياضي إمكانية تقديم تقييم شامل لمستوى النشاط البدني، الكشف المبكر عن الأخطاء الحركية، والمساهمة في تقليل الإصابات الناتجة عن الممارسات الرياضية الخاطئة. كما تلعب هذه الدراسات دورًا مهمًا في دعم برامج التدريب الرياضي وإعادة التأهيل الطبي.

يعتمد المشروع على استخدام تقنيات حديثة لجمع البيانات، مثل المستشعرات القابلة للارتداء أو الأجهزة الذكية، التي تقوم بتسجيل الإشارات الحركية المختلفة أثناء أداء الأنشطة الرياضية. يتم بعد ذلك معالجة هذه البيانات وتحليلها باستخدام خوارزميات وتقنيات تعلم الآلة لاستخلاص الخصائص المميزة لكل نشاط، وبناء نماذج قادرة على التعرف على الأنشطة الرياضية وتصنيفها بدقة.

يسعى هذا المشروع إلى الدمج بين الجانب النظري والتطبيقي، من خلال تقديم نموذج عملي يوضح كيفية الاستفادة من البيانات الحركية في بناء نظام ذكي لدراسة النشاط الرياضي. كما يهدف إلى إبراز دور التكنولوجيا الحديثة في خدمة المجال الصحي والرياضي، وفتح آفاق جديدة لتطوير تطبيقات ذكية تساهم في تحسين الأداء البدني، وتعزيز نمط الحياة النشط، ودعم الأبحاث المستقبلية في مجال دراسة النشاط البشري.

2.1 – منهجية المشروع :

تعتمد منهجية هذا المشروع على اتباع سلسلة من الخطوات المنهجية المتكاملة لتحليل وتصنيف النشاط البشري الرياضي اعتماداً على تقنيات رؤية الحاسوب والتعلم العميق، بدءاً من جمع البيانات وانتهاءً بتقييم أداء النموذج المقترح.

في المرحلة الأولى، تم تحديد هدف المشروع بشكل واضح، والمتمثل في بناء نظام ذكي قادر على التعرف على التمارين الرياضية المختلفة اعتماداً على أنماط حركة الجسم المستخرجة من مقاطع الفيديو.

في المرحلة الثانية، تم جمع البيانات على شكل مقاطع فيديو تمثل مجموعة من الأنشطة الرياضية المختلفة، حيث تم الاعتماد على تسجيل الحركات البشرية باستخدام كاميرا عادية دون الحاجة إلى أي مستشعرات قابلة للارتداء، مما يسهم في تبسيط النظام وزيادة قابليته للتطبيق العملي.

تلت ذلك مرحلة المعالجة المسبقة للبيانات، حيث تم استخدام إطار العمل MediaPipe لاستخراج نقاط مفاصل الجسم البشرية من كل إطار فيديو.

بعد ذلك، تم تنظيم هذه البيانات ومعالجتها من خلال إزالة الإطارات غير الصالحة وتوحيد شكل المدخلات، مع تقسيم البيانات إلى تسلسلات زمنية ثابتة الطول مكونة من 30 إطاراً لتمثيل الحركة بشكل ديناميكي.

في المرحلة التالية، تم استخراج الخصائص الحركية الأكثر تعبيراً عن التمارين الرياضية، والتي شملت زوايا المفاصل الرئيسية والمسافات المعيارية بين أجزاء الجسم بعد تطبيعها باستخدام مسافة مرجعية، بهدف تقليل تأثير اختلاف أحجام الأجسام والمسافات عن الكاميرا.

تُعد هذه الخصائص مدخلات أساسية للنموذج المقترح نظراً لقدرتها العالية على تمثيل الحركة بشكل دقيق.

بعد ذلك، تم استخدام خوارزميات التعلم العميق، وتحديدًا شبكة الذاكرة طويلة وقصيرة المدى ثنائية الاتجاه (Bidirectional LSTM)، لتعلم الأنماط الزمنية للحركات الرياضية وتصنيفها.

تم تدريب النموذج باستخدام بيانات التدريب، ثم تقييمه باستخدام مجموعة تحقق مستقلة، مع الاعتماد على مقاييس أداء معيارية مثل الدقة، والاسترجاع، ودرجة F1.

في المرحلة الأخيرة، تم تحليل نتائج النموذج وعرضها باستخدام أدوات تقييم علمية مثل مصفوفة الالتباس وتقارير التصنيف، إضافة إلى اختبار النموذج على مقاطع فيديو جديدة للتحقق من قدرته على التعميم.

أظهرت النتائج فعالية المنهجية المتبعة في تحقيق أهداف المشروع، مما يؤكد إمكانية استخدام هذا النهج في تطوير أنظمة ذكية لتحليل النشاط البشري الرياضي.

1.2.1- المشكلة البحثية للمشروع :

على الرغم من التطور الكبير في مجال رؤية الحاسوب وتعلم الآلة، إلا أن دراسة وتحليل النشاط البشري الرياضي ما زالت تواجه العديد من التحديات البحثية والتطبيقية. تتمثل المشكلة البحثية لهذا المشروع في صعوبة التعرف الدقيق والموثوق على الأنشطة الرياضية المختلفة وتحليلها بشكل آلي اعتماداً على مقاطع الفيديو، خاصة في ظل تنوع أنماط الحركة بين الأفراد، واختلاف أساليب الأداء البدني، وتباين ظروف التصوير مثل زاوية الكاميرا والإضاءة والمسافة عن المستخدم.

تعتمد العديد من الأساليب التقليدية في تقييم الأداء الرياضي على الملاحظة المباشرة أو التقييم اليدوي من قبل المدربين، وهي أساليب غالباً ما تكون عرضة للخطأ الذاتي وتفتقر إلى الدقة والاستمرارية.

كما أن بعض الأنظمة الذكية القائمة على تحليل الفيديو تعاني من محدودية في قدرتها على التعامل مع الضوضاء البصرية، وفقدان بعض مفاصل الجسم أثناء الحركة، وعدم استقرار اكتشاف النقاط الحركية في بعض الإطارات، مما يؤثر سلباً على دقة نتائج التحليل.

إضافة إلى ذلك، يبرز تحدٍ مهم يتمثل في صعوبة استخراج الخصائص الحركية الأكثر تعبيراً عن التمارين الرياضية، لا سيما عند وجود تشابه في أنماط الحركة بين بعض التمارين مثل تمارين الذراعين أو تمارين الجزء السفلي من الجسم.

كما أن اختيار الخوارزميات المناسبة القادرة على نمذجة التسلسل الزمني للحركة والتمييز بين هذه الأنشطة بدقة عالية يُعد من التحديات الأساسية في هذا المجال.

من هنا تنبع المشكلة البحثية لهذا المشروع في الحاجة إلى تصميم نظام ذكي وفعال يعتمد على تحليل الفيديو لاستخراج الخصائص الحركية ومعالجتها، بهدف التعرف على التمارين الرياضية وتصنيفها بشكل موثوق.

ويسعى هذا المشروع إلى معالجة هذه التحديات من خلال توظيف تقنيات رؤية الحاسوب والتعلم العميق، بما يساهم في دعم التطبيقات الحديثة في مجالات التدريب الرياضي والصحة الرقمية.

2.2.1 - أهداف المشروع :

يهدف هذا المشروع إلى تصميم وتطوير نظام ذكي لتحليل النشاط البشري الرياضي اعتماداً على تقنيات رؤية الحاسوب والتعلم العميق، من خلال معالجة مقاطع الفيديو واستخراج الخصائص الحركية التي تمثل حركة جسم الإنسان أثناء أداء التمارين الرياضية.

ويسعى المشروع إلى تقديم إطار عملي قادر على التعرف على نوع التمرين الرياضي بدقة عالية، بالاعتماد على التحليل الزمني لتسلسل الحركة، بدلاً من الاعتماد على التقييم البشري التقليدي أو القياسات اليدوية.

وتتمثل الأهداف التفصيلية للمشروع فيما يلي:

- 1- بناء نظام قادر على التعرف الآلي على مجموعة من التمارين الرياضية المختلفة، مثل تمارين الذراعين، وتمارين الضغط، وتمارين القرفصاء، اعتماداً على تحليل الحركة المستخرجة من مقاطع الفيديو.
- 2- الاستفادة من تقنيات تقدير وضعية الجسم (Pose Estimation) لاستخراج النقاط المفصلية لجسم الإنسان من كل إطار فيديو، بما يتيح تمثيل الحركة البشرية بشكل رقمي ومنظم وقابل للمعالجة الحسابية.
- 3- تحويل البيانات المرئية (الفيديو) إلى بيانات عددية تمثل الإحداثيات المفصلية والزوايا بين المفاصل، بما يسمح باستخدامها كمدخلات فعالة لنماذج التعلم الآلي والتعلم العميق.
- 4- معالجة البيانات الحركية المستخرجة من خلال تنقيتها من الضوضاء ومعالجة حالات فقدان الكشف لبعض النقاط المفصلية، بهدف تحسين جودة البيانات وزيادة استقرار أداء النموذج.
- 5- استخراج خصائص حركية مميزة لكل تمرين رياضي، مثل الزوايا بين المفاصل والمسافات النسبية المعيارية، والتي تساهم في تقليل تأثير اختلاف طول الجسم أو زاوية التصوير بين المستخدمين.
- 6- تقسيم البيانات الحركية إلى تسلسلات زمنية ثابتة الطول (Sequences) تمثل مراحل متتالية من الحركة، بما يتيح للنموذج فهم البنية الزمنية للتمرين الرياضي وليس مجرد تحليل إطارات منفصلة.

- 7- تصميم وتدريب نموذج قائم على الشبكات العصبية المتكررة ثنائية الاتجاه (BiLSTM) للاستفادة من المعلومات الزمنية السابقة واللاحقة في تسلسل الحركة، مما يعزز قدرة النموذج على التمييز بين التمارين المتشابهة في الشكل ولكن المختلفة في التسلسل الحركي.
- 8- تقييم أداء النموذج المقترح باستخدام مجموعة من المقاييس العلمية المعتمدة، مثل الدقة (Accuracy)، ومصفوفة الالتباس (Confusion Matrix)، ومقاييس Precision و Recall و F1-score، من أجل قياس كفاءة النموذج وموثوقية نتائجه بشكل شامل.
- 9- دراسة مدى قابلية النظام للتعميم عند تطبيقه على مقاطع فيديو جديدة لم تُستخدم أثناء التدريب، وذلك للتحقق من قدرة النموذج على التعامل مع اختلافات المستخدمين وظروف التصوير.
- 10- المساهمة في دعم التطبيقات الرياضية والصحية الذكية من خلال توفير نظام تحليلي يمكن استخدامه مستقبلاً في تقييم الأداء الرياضي، والمساعدة في تحسين جودة التدريب، ومتابعة النشاط البدني بطريقة موضوعية وآلية.

3.2.1 – الدراسة المرجعية :

شهد مجال تحليل النشاط البشري (Human Activity Recognition) تطوراً ملحوظاً في السنوات الأخيرة، نتيجة التقدم الكبير في تقنيات الاستشعار، ورؤية الحاسوب، وخوارزميات تعلم الآلة والتعلم العميق.

وقد ركزت العديد من الدراسات السابقة على تطوير أنظمة ذكية قادرة على التعرف على الأنشطة الرياضية وتحليل الحركة البشرية بدقة، باستخدام مصادر بيانات وأساليب مختلفة.

اعتمدت بعض الدراسات على المستشعرات القابلة للارتداء، مثل مقاييس التسارع والجيروسكوب، لما توفره من بيانات حركية دقيقة.

إلا أن هذا النوع من الأنظمة يتطلب تجهيزات إضافية وتفاعلاً مباشراً من المستخدم، مما قد يحد من سهولة الاستخدام في التطبيقات العملية.

في المقابل، اتجهت دراسات أخرى إلى استخدام مقاطع الفيديو وتقنيات رؤية الحاسوب لاستخراج حركة الجسم دون الحاجة إلى أجهزة إضافية.

مع ظهور تقنيات تقدير وضعية الجسم (Pose Estimation)، مثل OpenPose وMediaPipe، أصبح بالإمكان استخراج النقاط المفصلية لجسم الإنسان وتحويل الحركة إلى بيانات رقمية قابلة للتحليل. وقد استخدمت عدة أبحاث هذه التقنيات لاستخراج الخصائص الحركية ومن ثم تطبيق خوارزميات تعلم الآلة أو الشبكات العصبية المتكررة (RNN) و (LSTM) لتحليل التسلسل الزمني للحركة وتصنيف الأنشطة المختلفة.

ورغم النتائج الجيدة التي حققتها هذه الدراسات، إلا أن بعض التحديات ما زالت قائمة، مثل التأثير بزوايا التصوير، والاختلافات الفردية بين المستخدمين، والحاجة إلى نماذج قادرة على فهم البنية الزمنية للحركة بشكل أكثر دقة.

ومن هذا المنطلق، يأتي هذا المشروع ليستفيد من هذه الأعمال السابقة، مع التركيز على استخدام تحليل الفيديو وتقنيات التعلم العميق لتحسين دقة التعرف على التمارين الرياضية.

“من خلال مقارنة الدراسات السابقة، يتضح أن هناك اهتمامًا واسعًا باستخدام تقنيات تقدير وضعية الجسم وتحليل الحركة لاستنتاج الأنشطة المختلفة من بيانات الفيديو أو بيانات الاستشعار. تعتمد بعض الدراسات على تقنيات تحسين البيانات أو دمج نماذج CNN مع LSTM لتحقيق أداء أفضل، بينما تستخدم أخرى شبكات متقدمة مثل GCN للتعامل مع العلاقات المكانية في الهيكل العظمي. رغم أن العديد من هذه الأعمال يحقق نتائج جيدة، إلا أن تحديات مثل تأثير الإضاءة، زاوية التصوير، واختلاف المستخدمين لا تزال قائمة، مما يستدعي نماذج قادرة على استيعاب البعد الزمني للحركة بشكل أكثر دقة، وهو ما يتم التركيز عليه في هذا المشروع من خلال استخدام BiLSTM وتحليل الخصائص المعيارية”.

جدول مقارنة الدراسات المرجعية في تحليل الحركة والتعرّف على النشاط

المصدر	المميزات	نوع الخوارزمية	التقنية الرئيسية	نوع البيانات المستخدمة	الدراسة
https://arxiv.org/abs/2310.06068 (arXiv)	دقة تصل إلى (~96%) باستخدام Augmentation	SVM مع Data Augmentation	تحسين تقنيات رؤية الحاسوب	فيديو + نقاط الجسم	Augmenting Vision-Based Human Pose Estimation with Rotation Matrix
https://doi.org/10.22214/ijra.set.2025.70544 (IJRASET)	يعرض مقارنة بين نماذج مختلفة في الرؤية الحاسوبية	تقنيات متنوعة (OpenPose, CNN)	مقارنة شامل لتقنيات	فيديو + صور تحليل الحركة	A Comprehensive Review on

			تقدير الوضع		Human Activity and Fitness Tracker using Different Approaches
https://doi.org/10.1016/j.aej.2024.07.039 (ScienceDirect)	يوضّح تأثير الشبكات الرسومية في التعرّف على الحركة	Spatio- Temporal Graph Convolution al Networks	شبكات تحليل الحركة (GCN)	فيديو	Human pose estimation and action recognition on fitness behavior and fitness
https://link.springer.com/article/10.1186/s40537-024-00915-8 (Springer Nature Link)	نموذج فعال لتحليل الضغط والقرفصاء، مع تقييم LSTM	LSTM وتصنيف ثنائي	كشف وتعداد التكرارات	فيديو + تحليل الإطارات	Fitcam: detecting and counting repetitive exercises with deep learning
https://doi.org/10.32604/cm.c.2024.04806 1 (Tech Science)	دمج المعلومات المكانية والزمنية لتحقيق أداء قوي	بنية هجينة	مزيج CNN + LSTM	بيانات الاستشعار + فيديو	Combined CNN-LSTM for Recognizing Physical Activities
https://arxiv.org/abs/1706.08286 (arXiv)	يعالج الضوضاء في بيانات التسلسل الهيكلي	Spatio- Temporal LSTM	تحليل هيكل عظمي + Temporal	بيانات هيكل عظمي ثلاثي الأبعاد	Skeleton-Based Action Recognition Using Spatio- Temporal LSTM

الفصل الثاني :

الرياضة والذكاء الاصطناعي

1.2 - مقدمة :

تُعدّ الرياضة من أهم الأنشطة الإنسانية التي تسهم في تعزيز الصحة الجسدية والنفسية، كما تلعب دورًا أساسيًا في تحسين جودة الحياة والوقاية من العديد من الأمراض المزمنة. ومع التطور المتسارع في التقنيات الرقمية، لم يعد المجال الرياضي يعتمد فقط على الخبرة البشرية والملاحظة التقليدية، بل أصبح يستفيد بشكل متزايد من تقنيات الذكاء الاصطناعي وتحليل البيانات.

يسهم الذكاء الاصطناعي في تطوير المجال الرياضي من خلال تحليل الحركات البدنية بدقة عالية، ومراقبة الأداء الحركي، وتقييم جودة التمارين الرياضية بشكل موضوعي. ويعتمد ذلك على تقنيات متقدمة مثل الرؤية الحاسوبية والتعلم العميق، التي تتيح فهم النشاط الحركي للإنسان انطلاقًا من مقاطع الفيديو، واستخراج خصائص حركية مهمة مثل زوايا المفاصل، والمسافات النسبية بين أجزاء الجسم، والتسلسل الزمني للحركة.

وقد ساعدت نماذج التعلم العميق، ولا سيما الشبكات العصبية المتكررة مثل LSTM وBiLSTM، في تحسين دقة تحليل الأنشطة الرياضية، نظرًا لقدرتها على تمثيل العلاقات الزمنية بين الحركات المتعاقبة، وهو أمر جوهري في فهم التمارين الرياضية التي تعتمد على تسلسل من الوضعيات الحركية. كما أسهم استخدام تقنيات تقدير وضعية الجسم (Pose Estimation) مثل MediaPipe Pose في تحليل الحركة اعتمادًا على الفيديو فقط، دون الحاجة إلى أجهزة استشعار قابلة للارتداء، مما يزيد من مرونة الأنظمة الذكية وسهولة تطبيقها في البيئات المختلفة.

انطلاقًا من ذلك، يهدف هذا المشروع إلى الاستفادة من تقنيات الذكاء الاصطناعي والتعلم العميق للتعرف على التمارين الرياضية من مقاطع فيديو قصيرة، من خلال تحليل الخصائص الحركية والتسلسل الزمني للحركة. ويتيح هذا التوجه إمكانيات واسعة لتطوير تطبيقات التدريب الذكي، المتابعة الرياضية عن بُعد، وتصحيح الأخطاء الحركية، بما يسهم في دعم التحول الرقمي في المجال الرياضي وتحسين جودة الخدمات الرياضية والصحية.


2.2- شرح التمارين وانواعها :

يعتمد هذا المشروع على تحليل مجموعة من التمارين الرياضية الشائعة في صالات التدريب (الجيم)، والتي تتميز باختلاف أنماطها الحركية وتنوع المفاصل المستخدمة في أدائها. تم اختيار هذه التمارين بعناية نظرًا لملاءمتها لتقنيات تحليل الحركة المعتمدة على الفيديو، وسهولة تمييزها من خلال زوايا المفاصل والتسلسل الزمني للحركة. وفيما يلي شرح موجز لكل تمرين مع توضيح خصائصه الحركية.

1.2.2 تمرين Barbell Biceps Curl

يُعد تمرين Barbell Biceps Curl من أشهر تمارين تقوية الذراعين، حيث يستهدف بشكل أساسي العضلة الثنائية في الذراع (Biceps). يتم تنفيذ التمرين من خلال الوقوف بوضعية مستقيمة، وإمساك البار بكلتا اليدين، ثم رفعه تدريجيًا من وضع الذراعين الممدودتين إلى الأعلى مع ثني مفصل الكوع، ومن ثم العودة ببطء إلى الوضعية الابتدائية.

يعتمد هذا التمرين بشكل رئيسي على حركة مفصل الكوع، مع استقرار نسبي لمفصل الكتف، مما يجعله مناسبًا لتحليل زوايا المفاصل في أنظمة التعرف على النشاط البشري باستخدام الذكاء الاصطناعي. كما أن النمط الحركي المتكرر للتمرين يساعد نماذج التعلم العميق على اكتشاف التسلسل الزمني للحركة بسهولة.



2.2.2 تمرين Hammer Curl

يُشبه تمرين Hammer Curl تمرين البايكس التقليدي، إلا أنه يُنفذ باستخدام الدمبل مع توجيه راحتي اليدين نحو الداخل بدلاً من الوضعية الأفقية. يستهدف هذا التمرين العضلة العضدية إضافة إلى العضلة الثنائية في الذراع، ويتميز بحركة أكثر استقراراً لمفصل الكتف، مع تركيز واضح على ثني مفصل الكوع.


يُعد هذا الاختلاف في نمط الإمساك واتجاه الحركة عاملاً مهماً يساعد أنظمة الذكاء الصناعي على التمييز بين تمرين Hammer Curl وتمرين Barbell Biceps Curl ، رغم التشابه العام بينهما، وذلك من خلال تحليل زوايا المفاصل والمسافات النسبية بين نقاط الجسم.



3.2.2 تمرين Push-Up

يُعتبر تمرين Push-Up من التمارين الأساسية التي تعتمد على وزن الجسم، ويستهدف عضلات الصدر والكتفين والذراعين، بالإضافة إلى عضلات الجذع. يتم تنفيذ التمرين من خلال خفض الجسم نحو الأرض ثم رفعه باستخدام الذراعين، مع الحفاظ على استقامة الجسم أثناء الحركة.


يتميز هذا التمرين بتغيرات حركية متزامنة في عدة مفاصل، مثل الكتف والكواع والورك، مما يجعله غنيًا بالسّمات الحركية. وتُعد هذه الخصائص مناسبة لتحليل التسلسل الزمني للحركة باستخدام الشبكات العصبية المتكررة، حيث يتطلب التمرين تنسيقًا حركيًا مستمرًا بين أجزاء الجسم المختلفة.



4.2.2 تمرين Shoulder Press

يُعد تمرين Shoulder Press من التمارين الأساسية لتقوية عضلات الكتف، ويُنفذ من خلال رفع الوزن من مستوى الكتفين إلى أعلى الرأس باستخدام حركة عمودية. يعتمد هذا التمرين على تغير واضح في زوايا مفاصل الكتف والمرفق أثناء الصعود والهبوط.

تُسهّم هذه التغيرات الزاوية الواضحة في تسهيل عملية التعرف على التمرين ضمن أنظمة تحليل الحركة المعتمدة على الفيديو، كما تسمح باستخراج خصائص حركية مميزة تساعد على تصنيفه بدقة باستخدام نماذج التعلم العميق.



5.2.2 تمرين Squat

يُعد تمرين Squat من أهم تمارين تقوية الجزء السفلي من الجسم، حيث يستهدف عضلات الفخذين والورك والركبتين. يتم تنفيذ التمرين عن طريق ثني الركبتين وخفض الجسم نحو الأسفل، ثم العودة إلى وضع الوقوف بشكل متحكم فيه.

يتميز هذا التمرين بتغيرات كبيرة وواضحة في زوايا مفاصل الركبة والورك، مما يجعله من التمارين السهلة الاكتشاف في التحليل الحركي. كما أن الحركة العمودية للجسم أثناء الأداء توفر نمطاً حركياً مميزاً يسهل على أنظمة الذكاء الصناعي تمييزه عن باقي التمارين.



3.2 الذكاء الاصطناعي ومفاهيمه الأساسية

1.3.2 تعريف الذكاء:

يُعرّف الذكاء بأنه القدرة على الفهم والتعلّم والاستدلال وحل المشكلات، إضافةً إلى التكيف مع البيئة المحيطة واتخاذ القرارات المناسبة اعتمادًا على المعطيات المتاحة. ويشمل الذكاء مجموعة من العمليات العقلية مثل التفكير التحليلي، إدراك العلاقات، استخدام الخبرات السابقة، والتعامل مع مواقف جديدة بمرونة وكفاءة. وفي المجال التقني، يُستخدم مفهوم الذكاء لوصف قدرة الأنظمة الحاسوبية على محاكاة بعض جوانب السلوك الذكي لدى الإنسان، مثل التعلّم من البيانات، التعرّف على الأنماط، واتخاذ قرارات شبيهة مستقلة. ويُعد هذا المفهوم الأساس الذي تقوم عليه تطبيقات الذكاء الصناعي الحديثة في مختلف المجالات، ومنها تحليل الصور والفيديو والأنشطة الحركية

2.3.2 التعلّم الآلي (Machine Learning)

يُعد التعلّم الآلي أحد الفروع الأساسية للذكاء الصناعي، ويهدف إلى تمكين الأنظمة الحاسوبية من التعلّم تلقائيًا من البيانات دون الحاجة إلى برمجة صريحة لكل حالة. يعتمد هذا المجال على بناء نماذج قادرة على اكتشاف الأنماط والعلاقات داخل البيانات، واستخدامها في مهام مثل التنبؤ، التصنيف، واتخاذ القرار.

أنواع التعلّم الآلي:

ينقسم التعلّم الآلي إلى عدة أنواع رئيسية، من أبرزها:

- 1- التعلّم الخاضع للإشراف (Supervised Learning)، والذي يعتمد على بيانات مُعلّمة تحتوي على مدخلات معروفة والمخرجات، ويُستخدم بكثرة في مهام التصنيف مثل التعرف على التمارين الرياضية.
- 2- التعلّم غير الخاضع للإشراف (Unsupervised Learning)، ويُستخدم لاكتشاف الأنماط أو التجميعات داخل بيانات غير مُعلّمة.
- 3- التعلّم شبه الخاضع للإشراف (Semi-supervised Learning)، الذي يجمع بين

بيانات معلّمة وأخرى غير معلّمة لتحسين الأداء.
4- التعلّم المعزّز (Reinforcement Learning)، والذي يعتمد على مبدأ المكافأة والعقوبة لتعلّم السياسات المثلى لاتخاذ القرار.

البنية العامة للتعلّم الآلي
تتكوّن بنية أنظمة التعلّم الآلي عادةً من مجموعة بيانات تدريبية (Training Data)، تليها مرحلة استخراج السمات (Feature Extraction)، ثم تطبيق خوارزمية التعلّم لبناء نموذج قادر على التنبؤ أو التصنيف، وأخيراً مرحلة تقييم الأداء باستخدام مقاييس مناسبة

3.3.2 التعلّم العميق (Deep Learning)

التعلّم العميق هو فرع متقدم من التعلّم الآلي يعتمد على الشبكات العصبية الاصطناعية متعددة الطبقات.

يتميّز هذا النوع بقدرته على تعلّم السمات تلقائياً من البيانات الخام دون الحاجة إلى تصميم يدوي للخصائص، ويُستخدم على نطاق واسع في تطبيقات الرؤية الحاسوبية ومعالجة الفيديو.

أنواع نماذج التعلّم العميق

تشمل نماذج التعلّم العميق عدة أنواع، من أهمها الشبكات العصبية الالتفافية (CNN) المستخدمة في تحليل الصور والفيديو، والشبكات العصبية المتكررة (RNN) المخصصة للبيانات المتسلسلة، إضافة إلى شبكات LSTM و BiLSTM التي تتميز بقدرتها على فهم العلاقات الزمنية طويلة الأمد.

كما تشمل النماذج الحديثة الشبكات التوليدية (GAN) والمحولات (Transformers) التي تُستخدم في تطبيقات متقدمة ومتعددة الوسائط.

البنية العامة للتعلم العميق

تتكوّن الشبكات العميقة من طبقة إدخال، وعدة طبقات مخفية متتالية، وطبقة إخراج، إضافة إلى دالة خسارة تُستخدم لقياس الخطأ، وخوارزمية تحسين تعمل على تحديث أوزان الشبكة بهدف تقليل هذا الخطأ.

4.2 الشبكات العصبية المستخدمة في المشروع

1.4.2 الشبكات العصبية الالتفافية (CNN)

تُعد الشبكات العصبية الالتفافية (Convolutional Neural Networks) من أهم نماذج التعلم العميق المستخدمة في تحليل الصور والفيديو.

تعتمد هذه الشبكات على عمليات الالتفاف لاستخراج السمات المكانية مثل الحواف والأشكال والأنماط البصرية من البيانات المرئية.

تتكوّن البنية الأساسية لشبكات CNN من :

1. **طبقة الالتفاف (Convolution Layer)**
تستخرج السمات المكانية مثل الحواف والأشكال.
2. **طبقة التفعيل (Activation Layer)**
تضيف اللاخطية مثل ReLU.
3. **طبقة التجميع (Pooling Layer)**
تقلل أبعاد البيانات.
4. **طبقات كاملة الاتصال (Fully Connected Layers)**
تُستخدم للتصنيف النهائي.

2.4.2 الشبكات العصبية المتكررة (LSTM و BiLSTM)

تُعد الشبكات العصبية المتكررة (RNN) ، وخاصة نماذج LSTM و BiLSTM، مناسبة جداً لتحليل البيانات المتسلسلة مثل الفيديو، حيث تتميز بقدرتها على الاحتفاظ بالمعلومات عبر الزمن وفهم العلاقات بين الإطارات المتتالية. في هذا المشروع، يتم استخدام LSTM و BiLSTM لتحليل تسلسل الحركة في مقاطع الفيديو الرياضية، بحيث تستطيع النماذج تتبع التغيرات في زوايا المفاصل والمسافات بين النقاط الحيوية للجسم عبر الزمن. هذا يسمح للنموذج بالتعرف على نمط كل تمرين بدقة، حتى لو كانت حركاته مشابهة لتمرين أخرى، مما يعزز قدرة النظام على التمييز بين الأنشطة الرياضية المختلفة وتصنيفها بشكل موثوق.

5.2 تقييم أداء النماذج في المشروع

1.5.2 عملية تقييم النموذج

تُعد عملية تقييم النموذج خطوة أساسية للتحقق من كفاءة النظام وقدرته على التعميم. في مشاريع الرؤية الحاسوبية، تمر عملية التقييم بعدة مراحل

1. تقسيم البيانات

يتم تقسيم البيانات إلى مجموعة تدريب ومجموعة تحقق (Validation) أو اختبار.

2. تدريب النموذج

يتم تدريب CNN على مجموعة التدريب باستخدام دالة خسارة مناسبة.

3. التنبؤ على بيانات الاختبار

تُستخدم البيانات غير المرئية لتقييم قدرة النموذج على التعميم.

4. مقاييس التقييم

يتم استخدام مقاييس مثل:

- الدقة (Accuracy)
- الاستدعاء (Recall)
- الدقة الإيجابية (Precision)
- مصفوفة الالتباس (Confusion Matrix)

5. تحليل النتائج

تُستخدم الرسوم البيانية مثل منحنيات الخسارة والدقة لمقارنة أداء التدريب والتحقق.

في هذا المشروع، يتم الاستفادة من تقنيات التعلم العميق لتحليل الفيديو والتعرّف على التمارين الرياضية، حيث تُستخدم نماذج مثل CNN لاستخراج السمات البصرية، ثم يتم تحليل التسلسل الزمني للحركة باستخدام شبكات LSTM أو BiLSTM للوصول إلى تصنيف دقيق للتمارين.

2.5.2 مقاييس التقييم

1- الدقة (Accuracy)

تُعرّف الدقة (Accuracy) بأنها نسبة عدد التنبؤات الصحيحة التي قام بها النموذج إلى العدد الكلي للتنبؤات. وهي مقياس عام يعبر عن مدى صحة أداء النموذج في تصنيف التمارين الرياضية.

يتم حساب الدقة وفق المعادلة التالية:
الدقة = عدد التنبؤات الصحيحة ÷ العدد الكلي للعَيِّنات

في هذا المشروع، تُستخدم الدقة لتقييم قدرة النموذج على التعرف الصحيح على نوع التمرين الرياضي من مقاطع الفيديو. وتُعد الدقة مؤشرًا جيدًا عندما تكون البيانات متوازنة بين الفئات المختلفة من التمارين.

2- معامل (F1-Score) F1

يُعد معامل F1 من المقاييس المهمة التي تجمع بين مقياسي الدقة الإيجابية (Precision) والاستدعاء (Recall)، ويُستخدم بشكل خاص عندما تكون البيانات غير متوازنة.

يتم حساب معامل F1 وفق المعادلة التالية:
$$F1-Score = 2 \times (Precision \times Recall) \div (Precision + Recall)$$

يعكس هذا المقياس قدرة النموذج على تحقيق توازن بين:

- تقليل التنبؤات الخاطئة
- وعدم إغفال العينات الصحيحة

في مشروع التعرف على التمارين الرياضية، يساعد معامل F1 في تقييم أداء النموذج لكل تمرين على حدة، خاصة عند وجود تشابه حركي بين بعض التمارين.

3- مصفوفة الالتباس (Confusion Matrix)

مصفوفة الالتباس هي أداة تحليل تُستخدم لعرض أداء نموذج التصنيف بشكل تفصيلي، حيث تُبين عدد التنبؤات الصحيحة والخاطئة لكل فئة.

تتكون المصفوفة من:

- الصفوف التي تمثل القيم الحقيقية (True Labels)
- الأعمدة التي تمثل القيم المتوقعة (Predicted Labels)

تساعد مصفوفة الالتباس في هذا المشروع على:

- معرفة التمارين التي يميّزها النموذج بدقة عالية
- اكتشاف التمارين التي يحدث بينها خلط
- تحليل أسباب الأخطاء الناتجة عن تشابه الحركات

كما تُستخدم نتائج مصفوفة الالتباس لحساب مقاييس التقييم الأخرى مثل الدقة، الاستدعاء، ومعامل F1.

الفصل الثالث :

دراسة النشاط البشري (النشاط الرياضي)

1.2 شرح البيانات (Data Description)

1.1.3 وصف البيانات

تعتمد بيانات هذا المشروع على مقاطع فيديو قصيرة لتمارين رياضية مختلفة، وتُستخدم هذه المقاطع كمدخل رئيسي لنظام التعرف على النشاط الرياضي باستخدام تقنيات الذكاء الاصطناعي. تم اختيار البيانات بحيث تمثل حركات بشرية واضحة ومتكررة، مما يُسهّل عملية التحليل واستخراج الخصائص الحركية اللازمة للتصنيف الدقيق، ويُحسّن من أداء النموذج في مراحل التدريب والتقييم.

2.1.3 مصدر البيانات

تتكون مجموعة البيانات من مقاطع فيديو مخزنة محليًا، ومقسمة إلى مجلدات، بحيث يمثل كل مجلد نوعًا محددًا من التمارين الرياضية. يحتوي كل مجلد على عدة فيديوهات لأشخاص مختلفين يؤديون نفس التمرين، مع زوايا تصوير وظروف إضاءة متقاربة، لضمان تمثيل البيانات بشكل متناسق.

3.1.3 أنواع التمارين

تشمل مجموعة البيانات التمارين الرياضية التالية:

- Barbell Biceps Curl
- Hammer Curl
- Push-Up
- Shoulder Press
- Squat

تم اختيار هذه التمارين نظرًا لاختلاف أنماطها الحركية، مما يعزز قدرة النموذج على التمييز بين التمارين المختلفة وتصنيفها بدقة.

4.1.3 شكل البيانات

تبدأ البيانات الأولية في شكل مقاطع فيديو، ثم تُحوّل لاحقًا إلى تمثيل رقمي عددي من خلال الخطوات التالية:

1. استخراج نقاط الهيكل العظمي للجسم باستخدام **MediaPipe Pose**.
2. حساب زوايا المفاصل الرئيسية المرتبطة بالحركة.
3. حساب المسافات النسبية بين النقاط الهيكلية (Normalized Distances).

بعد ذلك، يتم تحويل البيانات إلى تسلسلات زمنية (Sequences) بطول ثابت، بحيث يمثل كل تسلسل حركة التمرين عبر عدد محدد من الإطارات، مما يسمح للنماذج بتحليل التسلسل الزمني للحركة بدقة.

5.1.3 خصائص البيانات

تتميز البيانات المستخدمة في المشروع بعدة نقاط قوية:

- التركيز على حركة الجسم بدلًا من مظهر الشخص أو الخلفية.
- مقاومة نسبيًا لاختلاف الطول والمسافة عن الكاميرا.
- مناسبة لتحليل التسلسل الزمني للحركة باستخدام الشبكات العصبية المتكررة (LSTM) و (BiLSTM).

6.1.3 تقسيم البيانات

تم تقسيم البيانات إلى مجموعتين رئيسيتين:

- **بيانات تدريب (Training Data):** لتدريب النماذج واستخراج الأنماط الحركية.
 - **بيانات تحقق (Validation Data):** لتقييم أداء النماذج والتأكد من قدرتها على التعميم على بيانات جديدة، مما يضمن عدالة التقييم وعدم التحيز لبيانات التدريب.
- تم اعتماد هذا التقسيم لضمان تقييم واقعي لأداء النموذج والحد من مشكلة فرط التعلم (Overfitting)

2.3 منهجية البيانات (Data Methodology) :

تعتمد منهجية البيانات في هذا المشروع على سلسلة من الخطوات المنظمة التي تهدف إلى تحويل مقاطع الفيديو الخام إلى تمثيل عددي مناسب لتحليل الحركة والتعرف على التمارين الرياضية باستخدام نماذج الذكاء الصناعي. تبدأ هذه المنهجية من مرحلة إدخال البيانات وتنتهي بالحصول على تسلسلات زمنية جاهزة للاستخدام في تدريب النماذج. في المرحلة الأولى، يتم إدخال مقاطع الفيديو الخاصة بالتمارين الرياضية إلى النظام، حيث تُعالج كل مقاطع الفيديو إطارًا تلو الآخر. تُستخدم مكتبة OpenCV لقراءة الفيديوهات واستخراج الإطارات المتتالية، مع الحفاظ على الترتيب الزمني للإطارات، لما لهذا الترتيب من أهمية كبيرة في تحليل الحركة.

في المرحلة الثانية، يتم تطبيق تقنية تقدير وضعية الجسم (Pose Estimation) باستخدام مكتبة MediaPipe Pose لاستخراج نقاط الهيكل العظمي للجسم البشري من كل إطار. تمثل هذه النقاط مواقع المفاصل الرئيسية مثل الكتفين، المرفقين، الوركين، الركبتين، والكاحلين، وتُعد الأساس في توصيف الحركة البشرية بشكل دقيق دون الاعتماد على مظهر الشخص أو خلفية المشهد. بعد ذلك، تُجرى مرحلة استخراج الخصائص الحركية، حيث يتم حساب زوايا المفاصل الرئيسية التي تعبر عن حركة التمرين، إضافةً إلى حساب المسافات النسبية المُطَبَّعة بين بعض النقاط الهيكلية. يهدف هذا التحويل إلى تمثيل الحركة بشكل عددي يعكس التغيرات الحركية الفعلية أثناء أداء التمرين، مع تقليل تأثير اختلاف طول الأشخاص أو بُعدهم عن الكاميرا.

في المرحلة التالية، تُنظَّم البيانات المستخرجة في شكل تسلسلات زمنية (Time Series)، حيث يتم تجميع عدد ثابت من الإطارات المتتالية في كل تسلسل. يمثل كل تسلسل دورة حركية كاملة أو جزءًا واضحًا من أداء التمرين، مما يسمح للنماذج المعتمدة على التسلسل الزمني، مثل الشبكات العصبية المتكررة، بفهم تطور الحركة عبر الزمن.

وأخيرًا، يتم تجهيز البيانات النهائية للاستخدام في مراحل التدريب والتقييم من خلال توحيد أبعاد البيانات والتأكد من خلوها من القيم غير الصالحة. تُعد هذه المنهجية المتكاملة لمعالجة البيانات خطوة أساسية في نجاح المشروع، إذ تضمن تقديم مدخلات عالية الجودة للنموذج، وتسهم بشكل مباشر في تحسين دقة التعرف على التمارين الرياضية وموثوقية النتائج النهائية.

4.3 تصميم النموذج وبناءه (Model Design and Architecture)

يعتمد تصميم النموذج في هذا المشروع على الاستفادة من طبيعة البيانات الحركية المستخرجة من مقاطع الفيديو، والتي تُعد بيانات زمنية متسلسلة تُعبر عن حركة الإنسان عبر الإطارات المتتالية. لذلك، تم اختيار بنية نموذج تجمع بين تمثيل الخصائص الحركية العددية وقدرة النماذج العميقة على فهم التسلسل الزمني للحركة، بهدف تحقيق تصنيف دقيق وموثوق للتمارين الرياضية.

في المرحلة الأولى من تصميم النموذج، يتم تحديد شكل بيانات الإدخال، حيث تُقدّم البيانات على هيئة تسلسلات زمنية بطول ثابت، يمثل كل تسلسل عددًا محددًا من الإطارات المتتالية. يحتوي كل إطار على مجموعة من الخصائص الحركية، مثل زوايا المفاصل والمسافات النسبية بين نقاط الهيكل العظمي. يسمح هذا التمثيل للنموذج بتحليل تطور الحركة عبر الزمن بدلًا من الاعتماد على إطار واحد فقط.

بعد تحديد بنية الإدخال، تم اختيار الشبكات العصبية المتكررة من نوع Long Short-Term Memory (LSTM) أو النسخة ثنائية الاتجاه BiLSTM كأساس لبناء النموذج. يعود هذا الاختيار إلى قدرة هذه الشبكات على الاحتفاظ بالمعلومات الزمنية المهمة والتعامل مع الاعتماد طويل المدى بين الإطارات، وهو أمر ضروري لفهم التمارين الرياضية التي تعتمد على تسلسل حركي متكامل وليس على وضعية ثابتة.

يتكون النموذج من طبقة أو أكثر من طبقات LSTM، حيث تعمل هذه الطبقات على تحليل التسلسل الزمني للخصائص الحركية واستخراج أنماط الحركة المميزة لكل تمرين. وفي حال استخدام BiLSTM، يتم تحليل التسلسل في الاتجاهين الأمامي والخلفي، مما يساهم في تحسين فهم السياق الزمني الكامل للحركة وزيادة دقة التصنيف.

بعد طبقات LSTM، يتم ربط النموذج بطبقات كاملة الاتصال (Fully Connected Layers)، والتي تهدف إلى تحويل السمات المستخرجة من التسلسل الزمني إلى تمثيل مناسب لعملية التصنيف. تُستخدم دوال تفعيل مناسبة مثل ReLU في الطبقات المخفية لتعزيز اللاخطية، في حين تُستخدم دالة Softmax في طبقة الإخراج لإنتاج احتمالية انتماء كل تسلسل إلى أحد التمارين الرياضية المعتمدة في المشروع.

لضمان استقرار عملية التدريب وتحسين أداء النموذج، تم اعتماد تقنيات تنظيمية مثل تطبيع البيانات قبل إدخالها إلى النموذج، إضافةً إلى استخدام أساليب تقلل من فرط التعلم (Overfitting) عند الحاجة، مثل تحديد عدد مناسب من الوحدات العصبية وعدد الطبقات. كما تم اختيار دالة خسارة ملائمة لمهام التصنيف متعدد الفئات، مثل Categorical Cross-Entropy، مع استخدام خوارزمية تحسين فعالة مثل Adam لتحديث أوزان النموذج أثناء التدريب.

يُعد هذا التصميم المتكامل للنموذج مناسباً لطبيعة مشكلة التعرف على التمارين الرياضية من الفيديو، حيث يجمع بين تمثيل حركي دقيق للحركة البشرية وقدرة عالية على تحليل التسلسل الزمني، مما يساهم في تحقيق نتائج دقيقة وموثوقة تدعم أهداف المشروع البحثية والتطبيقية.

5.3 مرحلة تدريب النموذج (Model Training)

تُعد مرحلة تدريب النموذج من المراحل الأساسية في هذا المشروع، حيث يتم فيها تمكين النموذج المصمم من تعلم الأنماط الحركية المميّزة لكل تمرين رياضي اعتماداً على البيانات الحركية المُعالجة مسبقاً. تهدف هذه المرحلة إلى ضبط أوزان النموذج الداخلية بحيث يكون قادراً على التنبؤ بنوع التمرين بدقة عالية عند إدخال بيانات جديدة غير مرئية.

قبل بدء عملية التدريب، تم تجهيز بيانات الإدخال على شكل تسلسلات زمنية ذات طول ثابت، مع التأكد من توحيد مقياس الخصائص الحركية باستخدام تقنيات التطبيع (Scaling)، وذلك لضمان استقرار عملية التعلم وتسريع عملية التقارب. بعد ذلك، تم تقسيم البيانات إلى مجموعتي تدريب وتحقيق، حيث تُستخدم بيانات التدريب لتحديث أوزان النموذج، بينما تُستخدم بيانات التحقق لمراقبة الأداء أثناء التدريب وتجنب فرط التعلم.

تم تدريب النموذج باستخدام خوارزمية التحسين Adam، نظراً لكفاءتها العالية في التعامل مع النماذج العميقة والبيانات الزمنية، وقدرتها على ضبط معدل التعلم تلقائياً أثناء التدريب. كما تم اعتماد دالة خسارة مناسبة لمهام التصنيف متعدد الفئات، وهي

دالة Categorical Cross-Entropy ، والتي تقيس الفرق بين التنبؤات الناتجة عن النموذج والقيم الحقيقية للتصنيفات.

تتم عملية التدريب عبر عدد محدد من الدورات التدريبية (Epochs) ، حيث يُمرّر كامل بيانات التدريب إلى النموذج في كل دورة. في كل Epoch ، يقوم النموذج بتنفيذ عملية الانتشار الأمامي (Forward Propagation) لحساب التنبؤات، تليها عملية الانتشار العكسي (Backpropagation) لحساب التدرجات وتحديث الأوزان بهدف تقليل قيمة دالة الخسارة. يتم تنفيذ التدريب على دفعات (Batches) ذات حجم محدد لتحسين كفاءة الذاكرة وتسريع عملية التدريب.

أثناء التدريب، يتم تتبع مجموعة من المؤشرات المهمة، مثل قيمة الخسارة ودقة التصنيف لكل من بيانات التدريب وبيانات التحقق. تُستخدم هذه المؤشرات لتقييم مدى تحسن أداء النموذج عبر الزمن، والكشف المبكر عن حالات فرط التعلم أو ضعف التعلم. وفي حال ملاحظة تدهور أداء النموذج على بيانات التحقق، يمكن تعديل عدد الدورات التدريبية أو بنية النموذج لتحقيق توازن أفضل بين التعلم والتعميم.

تُعد مرحلة تدريب النموذج خطوة حاسمة لضمان نجاح النظام المقترح، حيث تؤثر جودة التدريب بشكل مباشر على قدرة النموذج في التعرف على التمارين الرياضية المختلفة من خلال تحليل التسلسل الزمني للحركة. وقد ساهم الاعتماد على بيانات حركية دقيقة وبنية نموذج مناسبة في تحسين عملية التعلم وتحقيق أداء مستقر وفعال، مما يمهد للانتقال إلى مرحلة الاختبار والتقييم النهائي للنظام.

6.3 مرحلة الاختبار والتقييم (Testing and Evaluation)

تُعد مرحلة الاختبار والتقييم المرحلة الختامية في بناء النظام المقترح، حيث يتم فيها قياس مدى قدرة النموذج المدرب على التعميم والتعرف الصحيح على التمارين الرياضية عند التعامل مع بيانات لم يسبق له رؤيتها أثناء التدريب.

تهدف هذه المرحلة إلى تقييم الأداء الحقيقي للنموذج والتحقق من فعاليته وموثوقيته في تطبيقات عملية.

بعد الانتهاء من تدريب النموذج، تم استخدام مجموعة بيانات التحقق (Validation Data)

لاختبار النموذج وتقييم أدائه. حيث تم تمرير التسلسلات الزمنية المستخرجة من مقاطع الفيديو إلى النموذج، ثم مقارنة التنبؤات الناتجة مع القيم الحقيقية للتصنيفات، وذلك باستخدام مجموعة من المقاييس الكمية والرسومية.

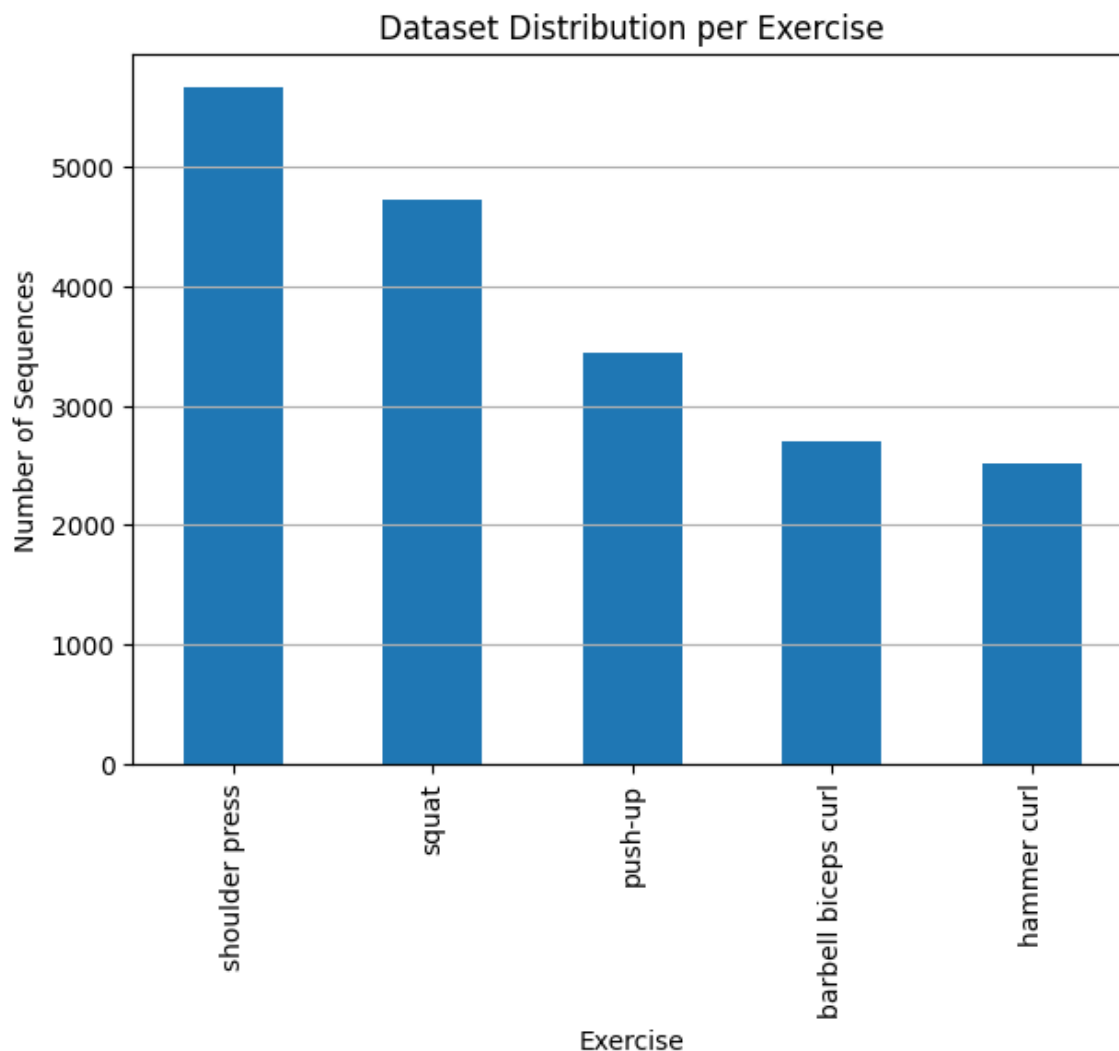
1.6.3 توزيع البيانات حسب التمارين الرياضية

(Dataset Distribution per Exercise)

يوضح هذا المخطط توزيع عدد العينات (الفيديوهات أو التسلسلات المستخرجة) لكل تمرين رياضي ضمن مجموعة البيانات.

يساعد هذا الشكل في تقييم مدى توازن البيانات بين الفئات المختلفة، حيث يؤثر عدم التوازن بشكل مباشر على أداء النموذج ودقته في التمييز بين التمارين.

يُستخدم هذا المخطط لتبرير نتائج النموذج لاحقاً، إذ إن التمارين ذات التمثيل الأكبر غالباً ما تحقق دقة أعلى مقارنة بالتمارين الأقل تمثيلاً.



الشكل (1) توزيع البيانات حسب نوع التمرين الرياضي

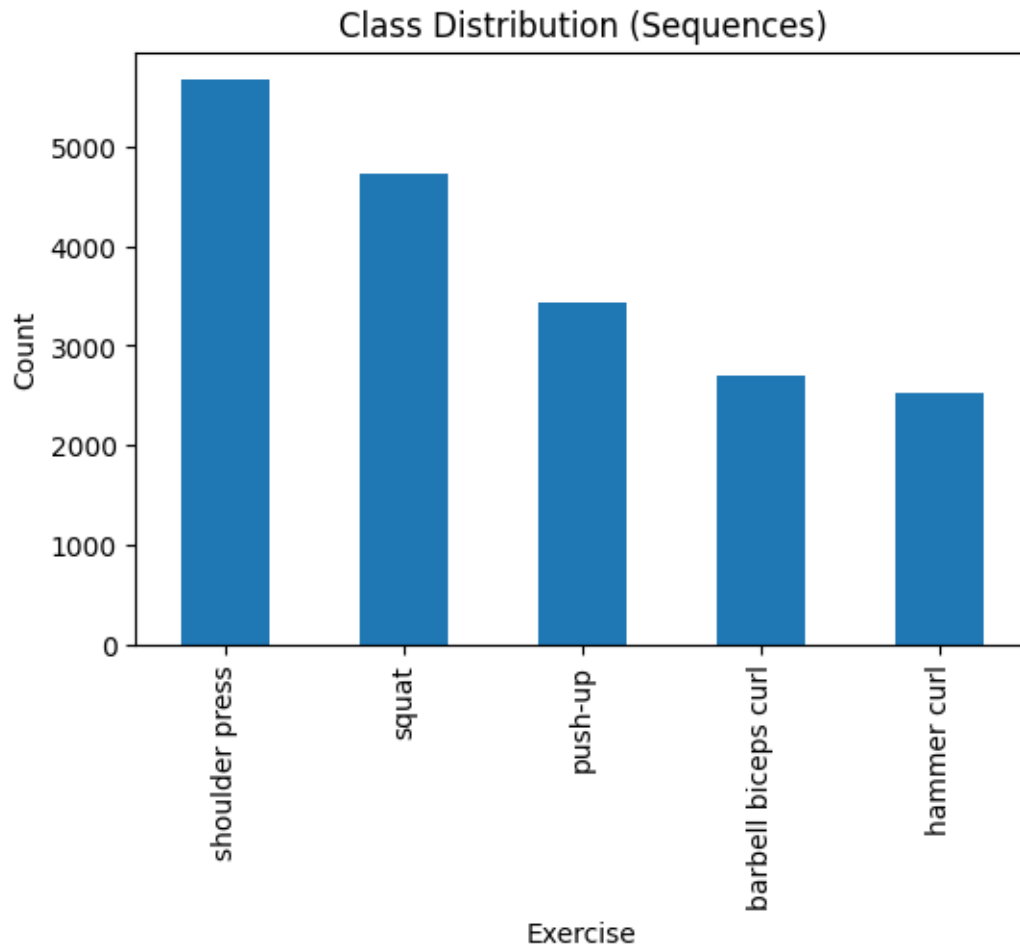
2.6.3 توزيع التسلسلات الزمنية (Sequences) لكل فئة

(Class Distribution – Sequences)

بعد تحويل البيانات إلى تسلسلات زمنية بطول ثابت، تم رسم مخطط يوضح عدد التسلسلات الناتجة لكل تمرين رياضي.

يعكس هذا الشكل الأثر الفعلي لعملية التقسيم الزمني على حجم البيانات المستخدمة في التدريب والتقييم.

يساعد هذا المخطط في التأكد من أن جميع التمارين ممثلة بشكل مناسب في شكلها الزمني، وهو أمر ضروري عند استخدام الشبكات العصبية المتكررة مثل LSTM وBiLSTM.




الشكل (2) توزيع التسلسلات الزمنية (Sequences) لكل تمرين رياضي

3.6.3 تقسيم بيانات التدريب والتحقق (Train / Validation Split)

يوضح هذا المخطط نسبة تقسيم البيانات إلى مجموعتي التدريب والتحقق. يهدف هذا التقسيم إلى تدريب النموذج على جزء من البيانات، ثم تقييمه على بيانات مستقلة لم يسبق له رؤيتها.

يساعد هذا الإجراء في:

- تقييم قدرة النموذج على التعميم
- تقليل احتمالية التعلم الزائد (Overfitting)
- ضمان عدالة وموثوقية نتائج التقييم




الشكل (3) مخطط تقسيم البيانات إلى مجموعة التدريب ومجموعة التحقق

4.6.3 مقارنة دقة التدريب والتحقق

(Training vs Validation Accuracy)

يعرض هذا المخطط منحنيات دقة النموذج لكل من بيانات التدريب وبيانات التحقق عبر عدد من الدورات التدريبية (Epochs). يُستخدم هذا الشكل لتحليل سلوك النموذج أثناء التدريب ومراقبة تحسّن الأداء مع مرور الزمن.

يشير تقارب منحنىي الدقة إلى أن النموذج قادر على التعلّم والتعميم بشكل جيد، بينما قد يدل التباعد الكبير بينهما على وجود فرط تعلّم.



الشكل (4) مقارنة دقة التدريب ودقة التحقق عبر مراحل التدريب


5.6.3 مقارنة الخسارة بين التدريب والتحقق

(Training vs Validation Loss)

يوضح هذا المخطط تغير قيمة دالة الخسارة لكل من بيانات التدريب والتحقق خلال مراحل التدريب. يعبر انخفاض الخسارة عن تحسن النموذج في تقليل الأخطاء أثناء التعلم.

يساعد هذا الشكل في:

- تقييم استقرار عملية التدريب
- التأكد من عدم حدوث تقلبات حادة في الأداء
- دعم نتائج الدقة بمؤشر كمي إضافي



الشكل (5) مقارنة خسارة التدريب وخسارة التحقق عبر مراحل التدريب


7.6.3 مصفوفة الالتباس

(Confusion Matrix)

تم استخدام مصفوفة الالتباس لتحليل أداء النموذج بشكل تفصيلي لكل تمرين رياضي. يوضح هذا المخطط عدد التنبؤات الصحيحة والخاطئة لكل فئة، حيث تمثل القيم القطرية التنبؤات الصحيحة، بينما تمثل القيم خارج القطر حالات الخلط بين التمارين.

يساعد هذا الشكل في:

- تحديد التمارين التي يميّزها النموذج بدقة عالية
- اكتشاف التمارين التي يحدث بينها التباس حركي
- تحليل أسباب الأخطاء الناتجة عن تشابه أنماط الحركة



الشكل (6) مصفوفة الالتباس لنتائج تصنيف التمارين الرياضية

8.6.3 تقرير التصنيف (Classification Report)

يعرض تقرير التصنيف مقاييس أداء النموذج لكل تمرين رياضي على حدة، وتشمل:

- Precision
- Recall
- F1-Score
- Support

يوفر هذا التقرير تقييمًا شاملاً ومتوازنًا لأداء النموذج، خاصة في حال وجود اختلاف في عدد العينات بين الفئات، ويُستخدم للتحقق من موثوقية النموذج في جميع التمارين

	precision	recall	f1-score	support
barbell biceps curl	0.99	0.99	0.99	541
hammer curl	1.00	0.99	1.00	504
push-up	1.00	1.00	1.00	688
shoulder press	0.99	1.00	1.00	1133
squat	1.00	1.00	1.00	944
accuracy			1.00	3810
macro avg	1.00	1.00	1.00	3810
weighted avg	1.00	1.00	1.00	3810

تقرير التصنيف (Classification Report) لنموذج التعرف على التمارين

9.6.3 دقة النموذج لكل تمرين رياضي (Class-wise Accuracy)

تم حساب دقة النموذج لكل تمرين رياضي بشكل مستقل باستخدام نتائج التنبؤ على بيانات التحقق. يوضح هذا التقييم مدى قدرة النموذج على التعرف الصحيح على كل تمرين على حدة، بعيدًا عن المتوسط العام للدقة.

يساعد هذا التحليل في:

- تقييم عدالة أداء النموذج بين الفئات
- تحديد التمارين التي تحتاج إلى تحسين أو بيانات إضافية
- دعم نتائج مصفوفة الالتباس وتقرير التصنيف

barbell biceps curl: 0.9889

hammer curl: 0.9940
push-up: 1.0000
shoulder press: 1.0000
squat: 0.9968

دقة النموذج لكل تمرين رياضي على حدة

7.3 الخلاصة والاستنتاج (Conclusion)

في ختام هذا المشروع، تم تقديم نظام ذكي للتعرف على التمارين الرياضية اعتمادًا على تحليل الحركة البشرية من مقاطع الفيديو باستخدام تقنيات الذكاء الاصطناعي والتعلم العميق. اعتمد النظام على استخراج نقاط الهيكل العظمي للجسم باستخدام MediaPipe Pose ، ثم تحويل الحركة إلى تمثيل عددي يعتمد على زوايا المفاصل والمسافات المُطَبَّعة، مما ساهم في تقليل تأثير العوامل الخارجية مثل شكل الجسم والخلفية وزاوية التصوير.

تم استخدام الشبكات العصبية المتكررة، وبشكل خاص نموذج BiLSTM ، لتحليل التسلسل الزمني للحركة، نظرًا لقدرتها العالية على فهم الاعتماد الزمني بين الإطارات المتتالية، وهو ما يعد عنصرًا أساسيًا في تحليل التمارين الرياضية.

أظهرت نتائج التدريب والتقييم تحسنًا واضحًا في دقة النموذج مع استقرار منحنيات الخسارة، مما يدل على كفاءة عملية التعلم وقدرة النموذج على التعميم.

أظهرت نتائج الاختبار، بما في ذلك مصفوفة الالتباس وتقرير التصنيف ودقة كل تمرين على حدة، أن النموذج قادر على التمييز بين التمارين الرياضية المختلفة بدقة عالية، مع انخفاض ملحوظ في حالات الخلط بين التمارين ذات الأنماط الحركية المتقاربة. كما أثبت استخدام التمثيل القائم على الحركة فقط فعاليته في بناء نظام أكثر مرونة وقابلية للتطبيق في بيئات مختلفة.

بناءً على النتائج المتحصل عليها، يمكن اعتبار هذا المشروع خطوة مهمة نحو تطوير أنظمة تدريب ذكية قادرة على متابعة الأداء الرياضي وتقييمه بشكل آلي. كما يفتح المجال لأعمال مستقبلية، مثل إضافة تمارين جديدة، وتحليل جودة الأداء وتصحيح

الأخطاء الحركية، وتطوير واجهات تفاعلية تعمل في الزمن الحقيقي لدعم التطبيقات الصحية والرياضية الحديثة.

المراجع

1. 2025
نظام تتبع اللياقة البدنية باستخدام الذكاء الاصطناعي والرؤية الحاسوبية
وتقنية MediaPipe.
International Journal for Research in Applied Science &
Engineering Technology.
الرابط:
<https://www.ijraset.com/research-paper/ai-human-fitness-tracker-using-computer-vision-with-mediapipe>
2. 2025
التعرّف على النشاط البشري باستخدام التعلم العميق ودمج CNN مع
LSTM.
مجلة Applied Sciences.
الرابط:
<https://www.mdpi.com/2076-3417/15/22/12173>
3. 2024
تصنيف التمارين الرياضية في الزمن الحقيقي باستخدام إطارات الفيديو.
arXiv preprint.
الرابط:
<https://arxiv.org/abs/2411.11548>

4. 2024

مراجعة شاملة لتقدير وضعية الجسم باستخدام التعلم العميق وتقديم التغذية الراجعة للحركة البدنية.

ScienceDirect.

الرابط:

<https://www.sciencedirect.com/science/article/pii/S2405844024126205>

5. 2022

تصنيف التمارين الرياضية بالاعتماد على نقاط الهيكل العظمي للجسم في الزمن الحقيقي.

arXiv preprint.

الرابط:

<https://arxiv.org/abs/2203.12111>

6. 2022

التعرّف على النشاط البشري باستخدام الشبكات المتبقية و BiLSTM.

مجلة. Sensors.

الرابط:

<https://pmc.ncbi.nlm.nih.gov/articles/PMC8778132/>

7. 2019

مجموعة بيانات متعددة الأنماط لتمرين النشاط البشري. (MEx Dataset)

arXiv preprint.

الرابط:

<https://arxiv.org/abs/1908.08992>